

Lista de Exercícios 1 – TP555 Inteligência Artificial e Machine Learning

Aluno: Bruno Ferreira Gomes

Matrícula:842

Ex1)

- a) **Inteligência:** É a capacidade de raciocinar e tomar decisões perante desafios encontrados, de forma clara, trilhando caminhos vistos como mais saudáveis. Assim como prever e desenvolver soluções lógicas e objetivas perante a capacidade cerebral do indivíduo.
- b) **Inteligência Artificial:** IA é uma forma de gerar capacidade de raciocínio lógico e objetivo em objetos, no caso, máquinas, que são interfaces físicas capazes de reproduzirem determinadas funções que foram implantadas em suas memórias. Assim, IA pode ser definido como uma humanização de tais máquinas, atribuindo características e habilidades do ser humano nelas.
- c) **Aprendizado de Máquina:** É a capacidade de uma máquina para resolver problemas de acordo com sua experiência e conhecimentos prévios sobre o problema. Desta forma, uma máquina que já tenha um conhecimento prévio sobre o assunto, e esteja em posse de exemplos, pode então agir, processando o problema e buscando chegar na solução com tudo o que já tem em sua memória.

Ex2)

T: Seria a tarefa de prever o tempo, utilizando de sua experiência E: dados climáticos prévios, assim.

D: A probabilidade de prever corretamente o tempo de uma data futura, seria a resposta correta, pois é a medida de desempenho do sistema, ao qual usa os recursos prévios para obter as respostas necessárias o mais próximo da realidade.

Ex3)

Assim como no exercício passado, **T: Tarefa de prever o tempo**, e, **E: Os dados climáticos históricos** que são usados como dados prévios para o sistema.

Ex4)

Considerando o sistema, visto as possíveis escolhas dos dados de entrada, a tarefa deve ser definida como **classificação**, pois os valores de saída são finitos, sendo possíveis somente Ensolarado, Nublado ou Chuvoso. Assim, à partir da análise de dados prévios, o algoritmo tem que decidir entre as opções possíveis.

Ex5)

Dispondo do algoritmo para fazer a análise, pode-se entender que esta previsão é aleatória, dispondo de uma enorme quantidade de possíveis soluções do problema, que é a previsão do valor da ação no dia seguinte. Assim, pode-se entender que o número de saída depende de uma enorme quantidade de valores para esta ação, sendo considerado infinito. Decorrente desta informação, a tarefa deve ser definida como **Regressão**.

Ex6)

O algoritmo a ser empregado deve ser o **Aprendizado por Reforço**. Pois, como definido, é um algoritmo utilizado para aprender sobre o ambiente, com interações do tipo tentativa e erro, devido ao fato de não possuir dados de treinamento. Esta definição cabe perfeitamente ao sistema pedido.

Ex7)

Para a resolução deste problema, podem ser aplicados os algoritmos **supervisionados**, **não supervisionados** e os **semi-supervisionados**. Estas várias opções podem ser aplicadas pois o problema em questão possui mais de uma solução. Assim, para os algoritmos supervisionados, a solução desejada já existe devido aos dados de treinamento, e para ela são adicionados os rótulos, o que para o problema, a analogia seria a que um grupo de clientes já é definido anteriormente, e novos clientes são adicionados a estes grupos. No caso do algoritmo não supervisionado, as máquinas recebem os dados de treinamento sem saber a tarefa que é necessária cumprir, assim, os algoritmos aprendem os padrões. A analogia para o problema seria a de que a máquina recebe os dados dos clientes, e vendo os padrões, esta é capaz de separar os grupos automaticamente. No caso dos semi-supervisionados, este usa características dos dois primeiros algoritmos, sendo assim, toma suas decisões baseadas nos fatos citados.

Ex8)

- a) Alocação de recursos em redes móveis

Referência: I. AlQerm and B. Shihada, "**A cooperative online learning scheme for resource allocation in 5G systems**," *2016 IEEE International Conference on Communications (ICC)*, Kuala Lumpur, 2016, pp. 1-7.

Método: Online learning – Algoritmo de aprendizado que usa reinforcement Q-learning

O uso do algoritmo realiza a alocação de potência e frequência para maximizar a taxa de transmissão do usuário no downlink. O objetivo é solucionar os problemas de alocação de recursos e de interferência nos sistemas 5G.

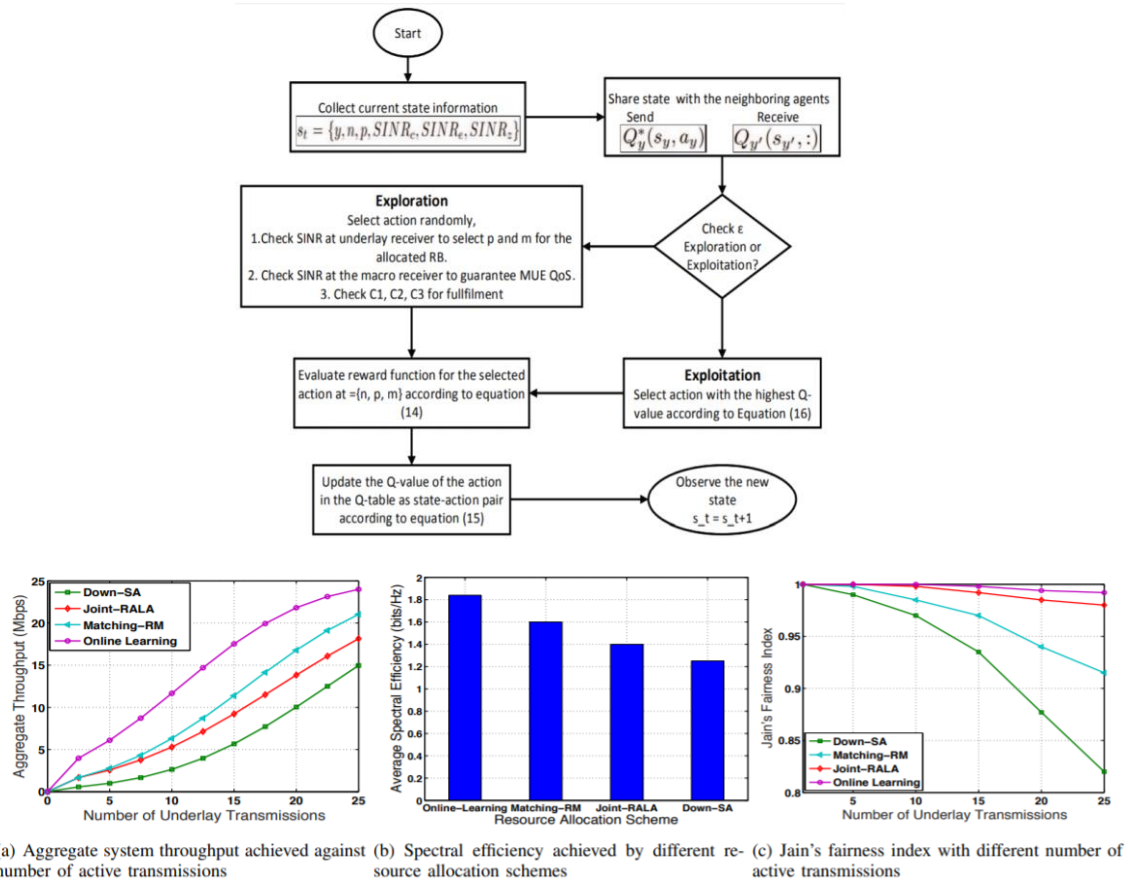


Fig. 3. Performance comparison of different resource allocation schemes in terms of throughput, spectral efficiency and fairness




Fig. 4. Performance comparison of different resource allocation schemes in terms of SINR and outage ratio

b) Mitigação de colisões em redes sem-fio e móveis

Referência: R. Mennes, M. Claeys, F. A. P. De Figueiredo, I. Jabandžić, I. Moerman and S. Latré, "Deep Learning-Based Spectrum Prediction Collision Avoidance for Hybrid Wireless Environments," in *IEEE Access*, vol. 7, pp. 45818-45830, 2019.

Método: Deep Learning, Convolutional Neural Networks (CNN)

Neste trabalho, os autores usam o algoritmo de ML para prever o comportamento de outras redes envolta, e assim, adapta o comportamento da própria rede e das redes em volta, gerando um maior throughput em todas elas, para tentar esquivar a colisão. A rede neural

convolucional é capaz de prever o uso do espectro das outras redes envolta, assim aplicando o algoritmo SPCA desenvolvido, que consegue diminuir as colisões.

c) Projeto e otimização de esquemas de modulação e codificação.

Referência: J. P. Leite, P. H. P. de Carvalho and R. D. Vieira, "**A flexible framework based on reinforcement learning for adaptive modulation and coding in OFDM wireless systems**," *2012 IEEE Wireless Communications and Networking Conference (WCNC)*, Paris, France, 2012, pp. 809-814.

Método: Reinforcement Learning

O processo de maximização da eficiência espectral foi tratado com o processo de decisão de Markov, onde a média da SNR foi utilizada para identificar as características do canal de rádio, e assim, foi encontrada uma associação entre os valores de SNR e os esquemas de codificação e modulação para este canal. Foram então aplicados esses dados em canais diferentes dos utilizados para treinamento, cujas interferências eram diferentes, e o algoritmo obteve sucesso, mantendo as características de SNR para diferentes valores de M bits utilizados para a modulação assim como para a codificação.

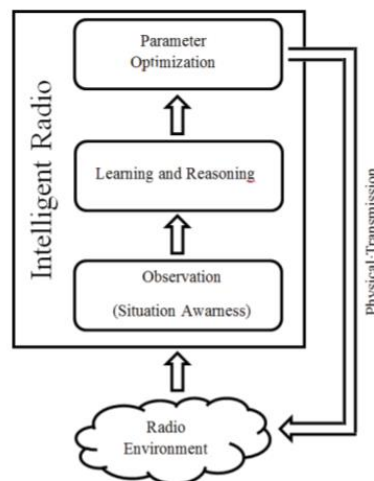


Fig. 1: Machine learning based framework for Transmitter Adaptation.




Fig. 2: Reinforcement learning interaction.

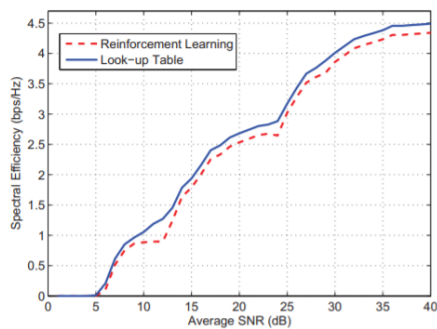


Fig. 5: Average spectral efficiency of the look-up table and the reinforcement learning technique under the suburban macrocell scenario.




Fig. 6: Average spectral efficiency of the look-up table and the reinforcement learning technique under the suburban macrocell scenario and colored interference. The interference power is eight times higher than the white noise variance.

d) Sensoriamento espectral

Referência: Y. Lu, P. Zhu, D. Wang and M. Fattouche, "**Machine learning techniques with probability vector for cooperative spectrum sensing in cognitive radio networks**," *2016 IEEE Wireless Communications and Networking Conference*, Doha, 2016, pp. 1-6.

Método: k-means Clustering

É proposto no artigo, um vetor de probabilidade bidimensional para sensoriamento espectral cooperativo. O Algoritmo de ML é usado para diminuir a dimensão do vetor de energia, resultando em uma precisão de detecção igual ou menor do que a forma padrão, utilizando um algoritmo de treinamento com curto tempo de duração e um tempo de classificação menor. Assim, quando comparados os dois métodos, o algoritmo de ML é capaz de realizar com precisão, a diminuição deste vetor de probabilidade que é diretamente implementado no cálculo do vetor de energia.

e) Posicionamento e localização em ambientes indoor.

Referência: M. Terán, H. Carrillo and C. Parra, "**WLAN-BLE Based Indoor Positioning System using Machine Learning Cloud Services**," *2018 IEEE 2nd Colombian Conference on Robotics and Automation (CCRA)*, Barranquilla, 2018, pp. 1-6.

Método: k-nearest Neighbours Classifier (k-NN) e Support Vector Machine (SVM)

Neste artigo, os autores propõem o design e a implementação de um sistema para localização usando tecnologias Wireless como WiFi e Bluetooth Low Energy baseados no conceito de IOT. O objetivo dos algoritmos de ML neste trabalho é traçar o melhor mapa de footprint do ambiente medido, considerando as melhores taxas de RSSI (Received Signal Strength Indicator). Foi primeiramente realizado uma etapa de aprendizado, no qual os dados

necessários para o treinamento foram obtidos. Foram reservados 70% do dataset para treinamento e o resto dos 30%, foram utilizados para testes e validação.

f) Roteamento de Redes

Referência: N. Kato *et al.*, "**The Deep Learning Vision for Heterogeneous Network Traffic Control: Proposal, Challenges, and Future Perspective**," in *IEEE Wireless Communications*, vol. 24, no. 3, pp. 146-153, June 2017.

Método: Deep Learning neural network

Neste trabalho, uma rede neural deep learning heterogênea é usada para aumentar o controle de tráfego. Este sistema se torna totalmente supervisionado. Ao contrário de redes neurais convencionais, esta rede é capaz de aprender e executar funções muito complexas, deixando de lado problemas como eficiência computacional e escalabilidade, o qual degradam o controle de tráfego na rede como o roteamento. Nesta rede proposta, cada uma das camadas escondidas processa uma transformação não linear da camada de trás. Além disso, um método de treinamento em camadas é utilizado para inicializar o aprendizado e utilizar o algoritmo de retropropagação para ajustar este treinamento. Assim, com um bom treinamento da rede, utilizando entradas e saídas bem definidas, o controle de tráfego pode ser muito melhorado quando comparado com outros tipos de redes.

g) Detecção e estimação de canal em sistemas de transmissão ópticos

Referência: A. S. Kashi *et al.*, "**Nonlinear Signal-to-Noise Ratio Estimation in Coherent Optical Fiber Transmission Systems Using Artificial Neural Networks**," in *Journal of Lightwave Technology*, vol. 36, no. 23, pp. 5424-5431, 1 Dec.1, 2018.

Método: Bayesian Regularization learning algorithm, um algoritmo de redes neurais artificiais (ANN)

No trabalho apresentado, os autores apresentam um método para estimar a SNR em sistemas de comunicação ópticos não lineares utilizando ANNs. O sistema se baseia na distorção causada por efeitos não lineares nos sistemas de fibra óptica. O algoritmo de ML é usado neste sistema com o intuito de prever o ruído adicionado nos sinais, sendo um vetor de amplitudes e fases, aos quais, sendo bem definidos, podem ser descompensados do sinal no final do processo. O sistema é treinado até que aprenda todos os possíveis casos simulados, e assim, depois podem estimar mais precisamente a resposta buscada.

h) Pré-distorção digital de não-linearidades de front-ends de RF

Referência: J. Sun, W. Shi, Z. Yang, J. Yang and G. Gui, "**Behavioral Modeling and Linearization of Wideband RF Power Amplifiers Using BiLSTM Networks for 5G Wireless Systems**," in *IEEE Transactions on Vehicular Technology*, vol. 68, no. 11, pp. 10348-10356, Nov. 2019.

Método: BiLSTM neural networks, a deep learning method

Neste artigo, um novo modelo de comportamento para um PA (Power Amplifier) aplicado em redes 5G foi criado utilizando as redes BiLSTM e reconciliando a sua não causalidade. Neste projeto, o método de treinamento é realizado de forma inversa. O uso desse sistema conseguiu mitigar o problema de ambiguidade de fase nos amplificadores testados. A arquitetura foi usada para construir um modelo chamado AI-DPD (digital predistortion baseado em IA), assim, à partir das medidas de IQ (Fase e Quadratura), a linearização da performance deste dispositivo foi realizada.

i) Segurança e robustez em redes de comunicação

Referência: B. Chatterjee, D. Das, S. Maity and S. Sen, "**RF-PUF: Enhancing IoT Security Through Authentication of Wireless Nodes Using In-Situ Machine Learning**," in *IEEE Internet of Things Journal*, vol. 6, no. 1, pp. 388-398, Feb. 2019.

Método: Deep Neural Networks, Artificial Neural Networks, gradient backpropagation algorithm

Neste projeto, os autores apresentam o RF-PUF, que é um framework de rede neural que permite autenticação em tempo real em nodes wireless, usando os efeitos de processos de variação inerentes em propriedades de RF nos transmissores e detecção no receptor. Esta rede é treinada com os dispositivos específicos capazes de realizar a função de autenticação entre o TX e o RX, avaliando diferentes estados do canal. Todos esses dispositivos são de certa forma escondidos nas camadas escondidas, por onde a conexão desta rede neural treinada pode realizar a comunicação.

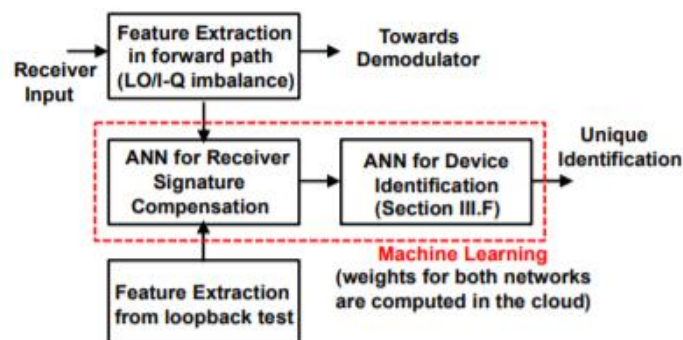


Fig. 9. One possible method that accounts for receiver non-idealities while performing device identification. A neural network performs the receiver signature compensation before device identification.

Performance comparison of RF-PUF with other standard PUFs

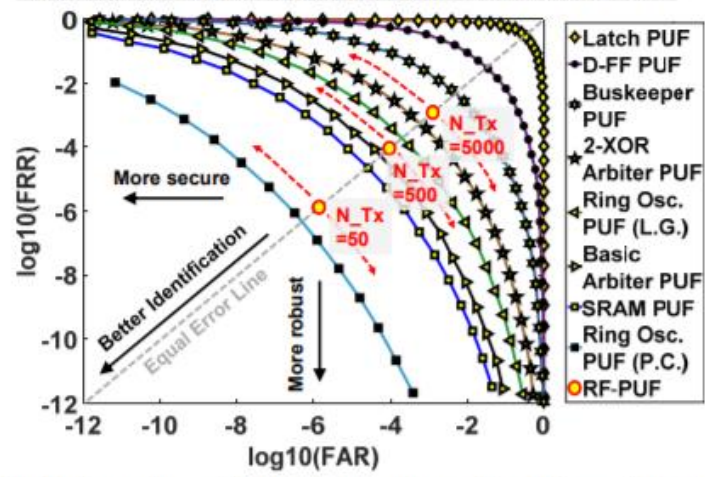


Fig. 12. Comparison of RF-PUF with various other PUFs available in literature. The values for False acceptance rate (FAR) and False Rejection Rate (FRR) for other PUFs are taken from [44].